

Statistiques

inférentielles

Lois

statistiques

Fonction de répartition :

- $F(x) = P(X \leq x) \rightarrow$ probabilité que X n'excède pas la valeur x .
- $P(a < X < b) = P(X < b) - P(X < a)$
 $= F(b) - F(a)$
- $F(x) = \int_{-\infty}^x f(t) dt$ où f est la densité de répartition d'une VA X .
- $\int_{-\infty}^{+\infty} f(t) dt = 1$; $f > 0$ sur $\mathbb{R}$.

Espérance, variance, écart-type :

- $E(X) = \sum_i x_i P(X = x_i) = \mu$
 $= \int_{\mathbb{R}} t f(t) dt$ (continue)
- $V(X) = E[(X - \mu)^2] = E(X^2) - E^2(X)$
 $= \int_{\mathbb{R}} f(t) (t - \mu)^2 dt$ (continue)

Moments:

- $m_r(X) = E(X^r)$
- $\mu_r(X) = E[(X - \mu)^r]$

Fonction caractéristique:

- $\varphi(t) = E(e^{itX})$

Lois usuelles:

- Loi de Gauss: $\mathcal{N}(\mu, \sigma)$ (ou normale)
 - $f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right)$ $E(X) = \mu$
 $V(X) = \sigma^2$
 - Si: $X \sim \mathcal{N}(\mu, \sigma)$ alors $Z = \frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1)$
est dite centrée réduite.
 - $\Phi(x) = P(Z < x)$ où $Z \sim \mathcal{N}(0, 1)$
 $\Phi(-x) = 1 - \Phi(x)$.
 Φ est symétrique par rapport à $x = 0$.
 - Si $X_1 \sim \mathcal{N}(\mu_1, \sigma_1)$ et $X_2 \sim \mathcal{N}(\mu_2, \sigma_2)$
sont deux VA indépendantes alors
 $X_1 + X_2 \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1 + \sigma_2)$.

• Loi du Khi-deux : $\chi^2(v)$ (ou Pearson)

- Soit $Z_1, \dots, Z_v$ une suite de VA indépendantes suivant $\mathcal{N}(0; 1)$.

$\sum_{i=1}^v Z_i^2$ suit $\chi^2(v)$ à v degrés de liberté.

- $\varphi(t) = (1 - 2it)^{-v/2}$
- $f(x) = \begin{cases} \frac{1}{2^{v/2} \Gamma(v/2)} x^{(v/2 - 1)} e^{-x/2} & \text{si } x > 0 \\ 0 & \text{sinon.} \end{cases}$

où $\Gamma(r) = \int_0^{+\infty} x^{r-1} e^{-x} dx$.

- Si $A \sim \chi^2(v)$ alors $E(A) = v$; $V(A) = 2v$

- $X_1 \sim \chi^2(v_1)$ et $X_2 \sim \chi^2(v_2)$ sont deux VA indépendantes alors $X_1 + X_2 \sim \chi^2(v_1 + v_2)$.

Loi de Student: $St(v)$

- Soit $Z \sim \mathcal{N}(0; 1)$ et $Q \sim \chi^2(v)$ deux VA indépendantes.

$$T = \frac{Z}{\sqrt{Q/v}} \sim St(v).$$

- $f(x) = \frac{1}{\sqrt{\pi v}} \frac{\Gamma(\frac{v+1}{2})}{\Gamma(v/2)} \frac{1}{(1+x^2/v)^{\frac{v+1}{2}}}.$

- Si $X \sim St(v)$; $E(X) = 0$ si $v \geq 2$.

$$V(X) = v/(v-2) \text{ si } v \geq 3$$

- La loi de Student converge vers $\mathcal{N}(0; 1)$
- Si $v=1$, loi de Cauchy (ou Lorentz).

Loi de Fisher - Snedecor: $F(v_1, v_2)$

- Soit $Q_1 \sim \chi^2(v_1)$ et $Q_2 \sim \chi^2(v_2)$ deux VA indépendantes.

$$F = \frac{Q_1/v_1}{Q_2/v_2} \sim F(v_1, v_2).$$

- $f(x) = \frac{\Gamma(\frac{v_1+v_2}{2})}{\Gamma(v_1/2)\Gamma(v_2/2)} \left(\frac{v_1}{v_2}\right)^{v_1/2} \frac{x^{v_1/2-1}}{(1+\frac{v_1}{v_2}x)^{\frac{v_1+v_2}{2}}}$
si $x > 0$; 0 sinon.

- Si $X \sim F(v_1, v_2)$ alors $E(X) = \frac{v_2}{v_2 - 2}$ si $v_2 \geq 3$; $V(X) = \frac{2 v_2^2 (v_1 + v_2 - 2)}{v_2 (v_2 - 2)^2 (v_2 - 4)}$ si $v_2 \geq 5$.

- Si $T \sim St(v)$ alors $T^2 \sim F(1, v)$.

Convergence

Inégalité de Markov (simplifiée):

Soient Y une VA de densité f , g une fonction croissante vérifiant $g(a) > 0$.
 $\forall a > 0, P(Y \geq a) \leq \frac{E(g(Y))}{g(a)}$.

Inégalité de Bienaymé-Tchebyshev:

Soit X une VA admettant une espérance μ et une variance finie σ^2 .

$$\forall \varepsilon > 0, P(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}.$$

Convergence en probabilité:

Soient $(X_n)_{n \in \mathbb{N}}$ une suite de VA et X une autre VA.

• $(X_n)_{n \in \mathbb{N}}$ converge en probabilité vers $l \in \mathbb{R}$ si :

$$\forall \varepsilon > 0, P(|X_n - l| > \varepsilon) \xrightarrow{n \rightarrow +\infty} 0$$

• $(X_n)_{n \in \mathbb{N}}$ converge en probabilité vers X si :

$$\forall \varepsilon > 0, P(|X_n - X| > \varepsilon) \xrightarrow{n \rightarrow +\infty} 0$$

- Si $E(X_n) \xrightarrow{n \rightarrow +\infty} l$ et $\sigma^2(X_n) \xrightarrow{n \rightarrow +\infty} 0$ alors $(X_n)_{n \in \mathbb{N}}$ converge en probabilité vers l .

Convergence en moyenne quadratique:

- $(X_n)_{n \in \mathbb{N}}$ converge en moyenne quadratique vers X si :

$$E((X_n - X)^2) \xrightarrow{n \rightarrow +\infty} 0$$
- Si $(X_n)_{n \in \mathbb{N}}$ converge en moyenne quadratique alors elle converge en probabilité.
- Si $E(X_n) \xrightarrow{n \rightarrow +\infty} p$ et $\sigma^2(X_n) \xrightarrow{n \rightarrow +\infty} 0$ alors (X_n) converge en moyenne quadratique vers p .

Loi faible des grands nombres:

Soient $(X_n)_{n \in \mathbb{N}}$ une suite de VA ayant la même espérance l et des variances vérifiant

$$\frac{1}{n^2} \sum_{i=1}^n \sigma_i^2 \xrightarrow{n \rightarrow +\infty} 0 ; S_n = \sum_{i=1}^n X_i.$$

La moyenne empirique S_n/n converge en probabilité vers l .

De plus si les X_n sont i.i.d alors

$\forall \varepsilon > 0, P(|\frac{S_n}{n} - E(X)| \geq \varepsilon) \xrightarrow{n \rightarrow +\infty} 0$, c'ad
 S_n/n converge en probabilité vers $E(X)$
(en notant $E(X)$ l'espérance commune).

Convergence en loi :

Soient $(X_n)_{n \in \mathbb{N}}$ une suite de VA de fonction de répartition F_n et X une VA de fonction de répartition F .

- $X_n \xrightarrow{\mathcal{L}} X$ si $\forall x$ où F est continue, les $F_n(x)$ convergent vers $F(x)$: $|F_n(x) - F(x)| \xrightarrow{n \rightarrow +\infty} 0$.
- $X_n \xrightarrow{\mathcal{P}} X \Rightarrow X_n \xrightarrow{\mathcal{L}} X$.
- Si (X_n) et X sont discrètes alors $X_n \xrightarrow{\mathcal{L}} X$
si et ssi $\forall x \in \mathbb{R} P(X_n = x) \xrightarrow{n \rightarrow +\infty} P(X = x)$.

Convergence de $\mathcal{H}(N, n, p)$ vers $\mathcal{B}(n, p)$:

n, p sont constants.

Soient (X_N) une suite de VA tq $X_N \sim \mathcal{H}(N, n, p)$
et $X \sim \mathcal{B}(n, p)$.

$$X_N \xrightarrow{\mathcal{L}} X.$$

Convergence de $\mathcal{B}(n, p)$ vers $\mathcal{P}(np)$:

Lorsque $n > 50$ et $p < 0,1$ on a:

Si $X_n \sim \mathcal{B}(n, p)$ et $X \sim \mathcal{P}(np)$ alors

$$X_n \xrightarrow{\mathcal{L}} Y.$$

(à refaire)

Théorème de continuité de Levy:

$$\forall t \in \mathbb{R} \quad \varphi_{X_n}(t) \xrightarrow{n \rightarrow +\infty} \varphi_X(t) \Leftrightarrow X_n \xrightarrow{\mathcal{L}} X$$

Théorème central limite:

Soient $(X_n)_{n \in \mathbb{N}}$ une suite de VA iid d'espérance μ et de variance $\sigma^2 \neq 0$; $S_n = \sum_{i=1}^n X_i$.

$$E(S_n) = n\mu \quad \text{et} \quad \sigma(S_n) = \sigma\sqrt{n}$$

$$O_n \text{ a } \frac{S_n - E(S_n)}{\sigma(S_n)} \xrightarrow{\mathcal{L}} Z \quad (Z \sim \mathcal{N}(0, 1))$$

Convergence de P vers N:

Soit $(X_n)_{n \in \mathbb{N}}$ une suite de VA suivant des lois de Poissons de paramètres λ_n .

Si $\lambda_n \xrightarrow{n \rightarrow +\infty} +\infty$ alors $\frac{X_n - \lambda_n}{\sqrt{\lambda_n}} \xrightarrow{\mathcal{L}} \mathbb{Z}$.

Convergence de B vers N: (th de Moivre-Laplace)

Soit $(X_n)_{n \in \mathbb{N}}$ une suite de VA suivant $\mathcal{B}(n, p)$.

$$\frac{X_n - np}{\sqrt{np(1-p)}} \xrightarrow{\mathcal{L}} \mathbb{Z}$$

ou encore $X_n \xrightarrow{\mathcal{L}} X$ où $X \sim \mathcal{N}(np, \sqrt{np(1-p)})$

lorsque $n > 30$, $np > 5$ et $n(1-p) > 5$.

($np > 15$ et $n(1-p) > 15$ est aussi valable)

Correction de continuité:

Lorsqu'on approche une loi discrète par une loi continue on a $P(X=k) \simeq P(k-0,5 \leq Y \leq k+0,5)$.

Echantillonnage et Estimations

Échantillon :

Soit X une VA sur Ω suivant une loi $\mathcal{L}$ (appelé loi mère).

Un échantillon de taille n est un n -uplet

$(X_1, \dots, X_n)$ de VA indépendante suivant $\mathcal{L}$.

Une réalisation de cet échantillon est un n -uplet $(x_1, \dots, x_n)$ de réels tq $\forall i \in [1; n]$ $X_i(\omega) = x_i$.

Statistique :

On appelle statistique sur un n échantillon une fonction de $(X_1, \dots, X_n)$.

Moyenne empirique :

On appelle moyenne (empirique) d'un échantillon la statistique notée $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$

Si $E(X) = \mu$ et $\sigma(X) = \sigma$ alors :

$$E(\bar{X}) = \mu \text{ et } V(\bar{X}) = \frac{\sigma^2}{n}.$$

de plus, lorsque $n \rightarrow +\infty$ alors

$\bar{X}$ converge en loi vers $\mathcal{N}(\mu, \sigma/\sqrt{n})$.

• Théorème:

Toute somme de VA normales et indépendantes est une VA normale.

Si $X \sim \mathcal{N}(\mu, \sigma)$ alors $\bar{X} \sim \mathcal{N}(\mu, \sigma/\sqrt{n})$.

Variance empirique:

On appelle variance empirique la statistique notée

$$\bar{S}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \quad \left(S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \right. \\ \left. \text{modifiée ou corrigée} \right)$$

Si $E(X) = \mu$, $\sigma(X) = \sigma$ et $\mu_4(X) = E((X-\mu)^4) = \mu_4$

alors: $E(\bar{S}^2) = \frac{n-1}{n} \sigma^2$

$$V(\bar{S}^2) = \frac{n-1}{n^3} [(n-1)\mu_4 - (n-3)\sigma^4] \underset{n \rightarrow \infty}{\sim} \frac{\mu_4 - \sigma^3}{n}$$

$\sqrt{n} \frac{\bar{S}^2 - \sigma^2}{\sqrt{\mu_4 - \sigma^3}}$ converge en loi vers $\mathcal{N}(0, 1)$.

Fréquence :

Soit $(X_1, \dots, X_n)$ un échantillon ayant pour loi mère $\mathcal{B}(p)$.

$F = \frac{1}{n} \sum_{i=1}^n X_i$ est la fréquence de la valeur 1 dans l'échantillon.

$$nF \sim \mathcal{B}(n, p).$$

$$E(F) = p \quad \text{Var}(F) = p(1-p)/n.$$

Lorsque $n \rightarrow +\infty$, F converge en loi vers $\mathcal{N}(p, \sqrt{\frac{p(1-p)}{n}})$.

Estimateur ponctuel :

On souhaite estimer un paramètre θ (moyenne μ , écart-type σ , proportion p) d'une population.

Un estimateur de θ est une statistique T dont la réalisation est envisagée comme une "bonne valeur" de θ .

On parle d'estimation de θ associée à cet estimateur la valeur prise par T au point $(x_1, \dots, x_n)$.

Biais:

On appelle biais d'un estimateur T pour la valeur θ la valeur $b_\theta(T) = E(T) - \theta$.

T est dit sans biais si $E(T) = \theta$.

Convergence et consistance:

Un estimateur T est convergent si $E(T) \xrightarrow{n \rightarrow +\infty} \theta$
consistant s'il converge en probabilité vers θ lorsque $n \rightarrow +\infty$.

• Théorème:

Si T est convergent et $V(T) \xrightarrow{n \rightarrow +\infty} 0$
alors T est consistant.

Erreur quadratique moyenne:

$$E((T - \theta)^2) = \text{Var}(T) + b_\theta^2(T)$$

Efficacité :

Soient T_1 et T_2 deux estimateurs sans biais. L'estimateur le plus efficace est celui dont la variance est minimale.

Estimateurs classiques :

- $\bar{X}$ est un estimateur sans biais de la moyenne μ .
Son estimation $\bar{x}$ est la moyenne observée dans une réalisation de l'échantillon.
- $\bar{S}^2$ est un estimateur biaisé consistant de σ^2 .
- $S^2 = \frac{n}{n-1} \bar{S}^2$ est un estimateur sans biais et consistant de σ^2 . Son estimation est $s^2 = \frac{n}{n-1} \sigma_e^2$ où σ_e est l'écart type observé dans une réalisation de l'échantillon.
- Si p est la fréquence d'un caractère, F est un estimateur sans biais et consistant de p . Son estimation est notée f .

Méthode du maximum de vraisemblance:

Soit X une VA réelle de loi continue ou discrète dont on veut estimer les paramètres $\theta_1, \dots, \theta_p$.

- On pose
$$f(x; \theta_1, \dots, \theta_p) = \begin{cases} f_{\theta_1, \dots, \theta_p}(x) & (1) \\ p_{\theta_1, \dots, \theta_p}(X=x) & (2) \end{cases}$$

(1) Si X est une VA continue de densité f .

(2) Si X est une VA discrète de probabilité P .

- $$L(x_1, \dots, x_n; \theta_1, \dots, \theta_p) = f(x_1, \dots, x_n; \theta_1, \dots, \theta_p) \\ = \prod_{i=1}^n f(x_i; \theta_1, \dots, \theta_p)$$

est la fonction de vraisemblance.

- On cherche la valeur $\hat{\theta}_i$ ^(on répète pour chaque i) qui maximise la fonction de vraisemblance. La condition :

$$\frac{\partial L(x_1, \dots, x_n; \theta_1, \dots, \theta_p)}{\partial \theta_i} = 0 \quad (\text{ou le } \ln)$$

permet de trouver $\hat{\theta}_i$.

(ou le $\ln$)
$$\frac{\partial L(x_1, \dots, x_n; \theta_1, \dots, \theta_p)}{\partial \theta_i}(\hat{\theta}_i) \leq 0 \quad \text{permet de}$$

vérifier que c'est un maximum local.

Il reste à vérifier que c'est un max global.

Si c'est le cas, on a que $\hat{\theta}_i$ est un estimateur du maximum de vraisemblance.

Intervalles de confiance

Donner un intervalle de confiance I à un seuil de confiance $\alpha \in [0;1]$ c'est donner un intervalle pour lequel la valeur cherchée a une probabilité α de ne pas y appartenir ($\underbrace{1-\alpha}_{\text{coeff de sécurité}}$ d'y appartenir).

Proportion :

On cherche $P(p \in I) = 1 - \alpha$

$$I =]f - z_{\alpha/2} \times \sqrt{\frac{f(1-f)}{n-1}}; f + z_{\alpha/2} \times \sqrt{\frac{f(1-f)}{n-1}}[$$

f est la fréquence d'apparition du caractère dans une population de n individus.

$z_{\alpha/2}$ se lit dans la table de la normale centrée réduite, (à la valeur α)

Moyenne :

On cherche $P(\mu \in I) = 1 - \alpha$

On calcule $\bar{x}$ de l'échantillon.

$$I =] \bar{x} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} ; \bar{x} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} [$$

Variance et écart-type :

On cherche $P(\sigma^2 \in I) = 1 - \alpha$

On calcule s^2 de l'échantillon.

$$I =] \frac{(n-1)s^2}{\chi^2_{\alpha/2}} ; \frac{(n-1)s^2}{\chi^2_{1-\alpha/2}} [$$

(on lit la
valeur en $\alpha/2$
et $(n-1)$)

Pour l'écart-type on prend les racines des bornes.

$$X_n \xrightarrow{e_1} X$$

$$X_n \xrightarrow{p} X$$

$$X_n \xrightarrow{L} X$$

$$\underbrace{E((X_n - X)^2) \rightarrow 0} \Rightarrow \underbrace{P(|X_n - X| > \varepsilon) \rightarrow 0} \Rightarrow \underbrace{P(X_n = x) \rightarrow P(X = x)} \\ |F_n(x) - F(x)| \rightarrow 0$$